

데이터 레이블링만 했습니다.

발표자 | 아이쿠톤간식도시락도둑이었는데데이터레이블링장인되었는데..
(이언호, 김정훈)

목차

- 사전 조사
- 일단 구현해보자
- 데이터셋 전처리(???)
- 모델 구성
- 결론



사전 조사

- 데이터셋을 보며, 어떻게 전처리해야 할까?
 - 대부분 강의 자료 필기 데이터셋.
몇몇 데이터는 인쇄체 사이에 글씨체가 숨어 있었다.
- 모델의 아키텍처를 우선적으로 계획해보자
 - 첫 모델에서 raw input image를 patch로 나눠, labeling을 하자!
 - 두 번째 모델에서 hand-writing image를 통해 분류하자!
- 모델의 보조 Feature?
 - 특정 강의 자료가 그 사람을 분류할 수 있는 feature가 될 수 있지 않을까?
 - 필기자의 필기 도구(펜 종류, 펜 두께, 글씨 색깔)이 feature가 될 수 있지 않을까?

사전 조사

- 아니 왜 데이터가 적은 건데. (특히 yh, ys)
그러면 이 데이터를 어떻게 처리해야 하지?
 - Augmentation
- 과적합 문제를 어떻게 해결할까?
 - 데이터 수가 적은데... backbone를 뭘로 써야 할까...

일단 구현해보자

Stage A — 손글씨 패치 검출기



학습 페이지의 패치를 `handwriting / printed / blank / ambiguous`로 라벨링합니다. 학습 시 `printed+blank`를 non-handwriting으로 병합해 MobileNetV3-small 이진 검출기를 학습하고, 829장 전체의 손글씨 확률맵을 생성합니다. 테스트 데이터는 이 노트북에서 일절 읽지 않습니다. 생성된 `hwmap.tar.gz`는 두 Stage B 노트북이 공통으로 사용합니다.

```
# [A1] 환경 · CONFIG · 데이터 준비
import os, sys, subprocess, random, json, time, glob, re, math, shutil, io, hashlib
if "google.colab" in sys.modules or os.path.exists("/content"):
    try:
        from google.colab import drive
        drive.mount("/content/drive")
    except Exception as e: print(f"🔌 Drive 마운트 생략: {e}")
import numpy as np, pandas as pd, cv2, torch
import torch.nn as nn
from torch.utils.data import Dataset, DataLoader, WeightedRandomSampler
from torchvision import transforms as T
from PIL import Image
import matplotlib.pyplot as plt
from tqdm.auto import tqdm
from sklearn.model_selection import StratifiedGroupKFold
from sklearn.metrics import accuracy_score, f1_score, confusion_matrix

CFG = dict(
    DRIVE_ROOT="/content/drive/MyDrive/AIKUTHON",
    DRIVE_ZIP_PATH="/content/drive/MyDrive/AIKUTHON/12-aikuthon.zip",
    DATA_ROOT="/content/data/12-aikuthon", CACHE_DIR="/content/cache",
```

Python

일단 구현해보자



일단 구현해보자

wj / hw 0.197
yh / hw 0.197
ys / hw 0.197
ysh / hw 0.197

페이지 coverage gate 미달: 전체>=85%, writer 최저>=70% 필요. A7 실행 금지.

csb / hw 0.197
csh / hw 0.798
ehj / hw 0.490
lc / hw 0.199
sj / hw 0.568
sy / hw 0.773
wj / hw 0.550
yh / hw 0.475
ys / hw 0.290
ysh / hw 0.882

Chapter 5 Topics

- Introduction
- Arithmetic Circuits
- Number Systems
- Sequential Building Blocks
- Memory Arrays
- Logic Arrays

Example: subspaces

Find dimension and basis of $R(A)$, $N(A)$

$A = \begin{pmatrix} 0 & 2 & 3 & 4 \\ 0 & 0 & 7 & 8 \\ 0 & 10 & 11 & 12 \end{pmatrix}$

$N(A) = \text{span} \left\{ \begin{pmatrix} 1 \\ 0 \\ 0 \\ 0 \end{pmatrix}, \begin{pmatrix} 0 \\ 1 \\ 0 \\ 0 \end{pmatrix} \right\}$

$R(A) = \text{span} \left\{ \begin{pmatrix} 2 \\ 0 \\ 10 \end{pmatrix}, \begin{pmatrix} 3 \\ 7 \\ 11 \end{pmatrix} \right\}$

Least Effective

Persistent storage

Definition of Coordinate Vector

Useful norms

$\|x\|_1 = \sum |x_i|$
 $\|x\|_2 = \sqrt{\sum x_i^2}$
 $\|x\|_\infty = \max |x_i|$

$\|x\|_1 = 1 \Rightarrow x_1 = 1, x_2 = 0$
 $\|x\|_2 = 1 \Rightarrow x_1 = \frac{1}{\sqrt{2}}, x_2 = \frac{1}{\sqrt{2}}$
 $\|x\|_\infty = 1 \Rightarrow x_1 = 1, x_2 = 1$

for n in [1, 2, 4, 8]:
ok = manifest.hw_candidates >= n

일단 구현해보자

- 텍스트 인식 관련 backbone를 사용해 보자. (TrOCR, DiT)
 - Colab 결제. GPU 좋은 거 썼는데. 모델의 크기도 크고... 학습도 잘 안 되고... 너무 과적합되는 거 같음... (Transformer 별로인 듯.)

✓	submission_full_bias.csv Complete · Justgoyourway · 8h ago · 1	0.13867	0.12222	☐
✓	submission (2).csv Complete · Justgoyourway · 8h ago · resnet	0.13867	0.12222	☐
✓	submission (1).csv Complete · Justgoyourway · 9h ago · trocr	0.14149	0.10598	☐
✓	submission_baseline_gray.csv Complete · Junghoon Kim · 12h ago	0.19637	0.16772	☐
✓	submission_clip.csv Complete · Junghoon Kim · 13h ago · 제발	0.05468	0.05701	☐
✓	submission.csv Complete · Justgoyourway · 14h ago	0.01654	0.01978	☐
✓	sample_submission.csv Complete · Junghoon Kim · 17h ago	0.01654	0.01978	☐

일단 구현해보자

1. 일단... backbone 버리자. Baseline의 score가 우리 모델보다 더 높네.
Baseline를 제공한 이유가 있을 거임.
Baseline을 기반으로 모델 성능을 향상시키자.
2. 근데... 이렇게 patch로 나뉘고 labeling해도
noise가 너무 많은 거 아님?





일단 구현해보자

- 그러면 noise 없는 깔끔한 손글씨만 뽑으면 되는 거 아님? Let's go.



데이터셋 전처리(NGD_{노가다})




약 1050개 전처리

AIKUTHEON

모델링

- Baseline이 ResNet 기반. 데이터가 적은 상황. 경량화 모델 가능할 듯.
- 추가적으로, 전처리된 데이터셋의 해상도가 각각 다름.
또한 이미지 파일마다 글씨체의 굵기가 다름. 글씨체 굵기 통일.
- Augmentation : background(줄, 점, 격자 등), rotation(4°), 밝기, 대비 등

일단 해보자! 우리에게겐 좋은 데이터셋이 있으니!!



모델링

우선 펜 굵기만 처리해봤는데...
오. 일단 우리가 만든 모델 중에서 SOTA



submission (5).csv

Complete · Justgoyourway · 5h ago · nahhhhhhhhhhhhhhhhhhh

0.21160

0.14991



나머지 augmentation을 적용해볼까... 오.....??????????



submission (6).csv

Complete · Justgoyourway · 4h ago · d

0.30877

0.30232



모델링

Ablation study를 시도.

patch 크기 바꿔보자 (실패)

angle $4^{\circ} > 3^{\circ}$ (실패)

Seed 3개, 앙상블 시도 (실패)

Seed를 바꿔가며 모델 성능 테스트 (실패)

ResNet16 > ResNet34 (실패)

뭐가 문제지...? SOTA를 다시 Train시켜... submit 했는데, 0.15xx 정도 뚝...??

> train checkpoint 잘 걸려서... train이 잘 됐었던 거 같음.

모델링

일반 FC + CrossEntropy 대신 ArcFace 헤드로 교체 시도 (실패)

아직 데이터셋과 적합한 백본 모델을 찾지 못했다는 가설 하에,
ConvNeXt-Tiny 백본 교체 시도 (실패)



EfficientNet-B0 + 정규화 강화 시도(mix up/ dropout) (실패)

MobileNetV3-Small (실패)

모델링

✓	submission (11).csv Complete · Justgoyourway · 3h ago · d	0.10405	0.05231	☐
✓	submission (10).csv Complete · Justgoyourway · 3h ago · d	0.16198	0.16688	☐
✓	submission (9).csv Complete · Justgoyourway · 3h ago · d	0.15590	0.15818	☐
✓	submission (8).csv Complete · Justgoyourway · 4h ago · d	0.21186	0.18755	☐
✓	submission (7).csv Complete · Justgoyourway · 4h ago · d	0.22991	0.22040	☐

모델링



결론

데이터의 품질은 모델의 성능을 결정한다.

Noise를 없애기 위해 직접 손수 labeling 하는 것
또한 효과적인 방법일 수 있다.

같은 모델이어도, Train이 어떻게 되느냐에 따라 성능이 많이 바뀔 수 있다.

손이 조금만 더 빨랐더라면... 데이터셋 말고 모델 더 만져볼 수 있었을 걸...

마음만큼은 1등이었다...